BIOESTADÍSTICA · SEMANA 2 · 2026-II

Regresión Lineal Simple y Múltiple

De comparar grupos a modelar relaciones entre variables continuas — RA1 · RA2

Javier Rodríguez Barrios

Maestría en Ecología y Biodiversidad · Universidad del Magdalena

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

1

AGENDA DE LA SESIÓN

De comparar grupos a modelar variables

Correlación vs. regresión
Qué pregunta responde cada una. RA2

Regresión lineal simple
El modelo, sus coeficientes y su inferencia. RA2

Supuestos y diagnóstico
Qué se verifica antes de confiar en el modelo. RA2

Regresión múltiple
Varios predictores: efectos parciales y colinealidad. RA2

Selección de modelos
Comparación con AIC y pruebas F anidadas. RA2

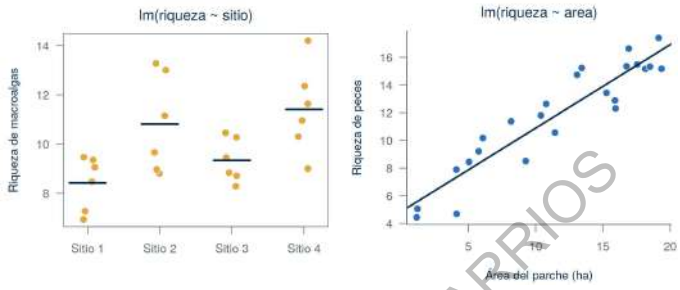
Síntesis y ejercicio
Lista de verificación y aplicación al proyecto de grado. RA1 · RA2

2

ANTES DE EMPEZAR

De comparar grupos a relacionar variables

- En la Semana 1 se compararon **medias entre grupos**: ¿difiere la cobertura entre dos bahías?, ¿entre cuatro sitios?
- Ahora la pregunta cambia de forma: ¿cómo cambia una **variable continua** a medida que cambia otra?
- La lógica inferencial es la misma (H_0, valor p, IC), aplicada a una **pendiente** en lugar de a una diferencia de medias.
- Esta sesión cierra la **Evidencia 1** (regresión) y prepara la sesión de **GLM** del sábado en la tarde.



"ANOVA y regresión son dos caras del mismo modelo lineal: en R, ambos se ajustan con lm()."

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

LA PRIMERA DECISIÓN

Correlación vs. regresión: ¿cuál se necesita?

Correlación

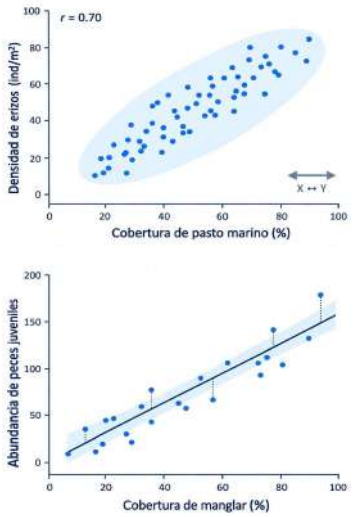
`cor.test(x, y)`

Ambas variables se **miden** (ninguna se fija) y se evalúa si **varían juntas (asociación)**, sin definer causalidad. Resume intensidad y dirección con el coeficiente r (Pearson, Spearman, Kendall).

Regresión

`lm(y ~ x)`

Hay relación de causalidad. Una variable se trata como **respuesta (Y)** y otra como **predictor (X)**; se estima cuánto cambia Y por unidad de X. En estudios observacionales describe asociación, no causalidad.



LA PRIMERA DECISIÓN

Correlación vs. regresión: ¿cuál se necesita?

Ejemplo — Macroalgas Rhodophyta

En 16 sitios, la **cobertura de sustrato rocoso colonizado** (%) y la **biomasa de Rhodophyta** (g/m²) están correlacionadas:

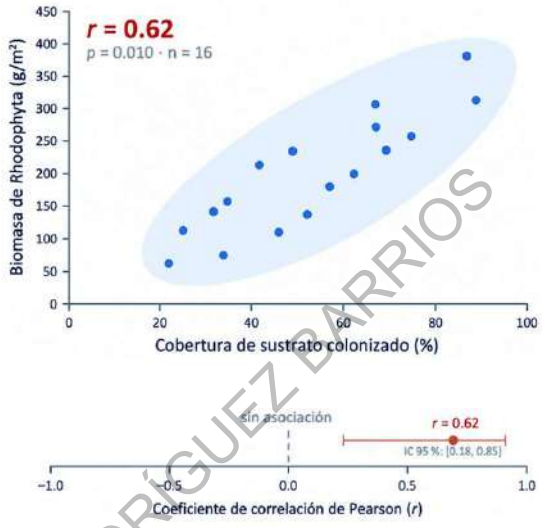
r = 0.62, IC 95 % = [0.18, 0.85].

Si el objetivo fuera **proyectar la biomasa a partir de la cobertura** en sitios no muestreados, la pregunta pasaría a ser de **regresión**.

```
cor.test(algas$cobertura_pct, algas$biomasa_gm2)
```

```
    Pearson's product-moment correlation

data:  algas$cobertura_pct and algas$biomasa_gm2
t = 2.9579, df = 14, p-value = 0.01038
alternative hypothesis: true correlation is not equal to 0
95 percent confidence interval:
 0.1796960 0.8534886
sample estimates:
      cor  0.6201598
```



5

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

EL MODELO

Regresión lineal simple

$$Y = \beta_0 + \beta_1 X + \varepsilon$$

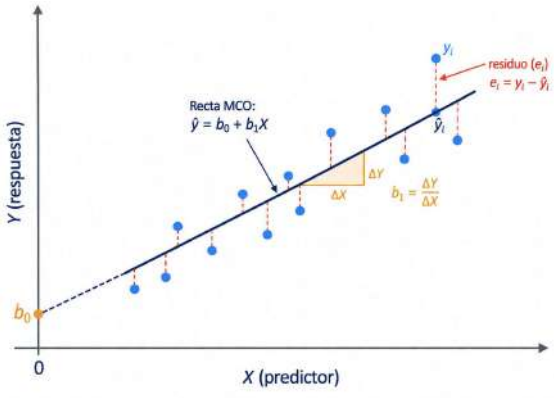
Cómo se ajusta

Se busca la recta que **minimiza la suma de los residuos al cuadrado** (mínimos cuadrados ordinarios). Los parámetros poblacionales (β) se estiman con coeficientes muestrales (b).

Los dos coeficientes

b_0 (intercepto): valor esperado de Y cuando X = 0.

b_1 (pendiente): cambio promedio de Y por cada unidad que aumenta X.



Ejemplo

¿**Cuánto cambia la riqueza de peces** al aumentar el **área de un parche de manglar**?

R./ b_1 responde esa pregunta, **en la escala en que se ajusta el modelo** (ver ejemplo siguiente).

Ojo: b_0 solo tiene sentido biológico si X = 0 está dentro del rango observado.

6

EJEMPLO TRABAJADO

Riqueza de peces vs. área de manglar

Pregunta: ¿Aumenta la **riqueza** de especies de peces con el **área del parche** de manglar? (n = 20 parches).

R./ Ambas variables se transforman a **$\log_{10}$**: la relación especie-área rara vez es lineal en escala original, pero sí en escala logarítmica.

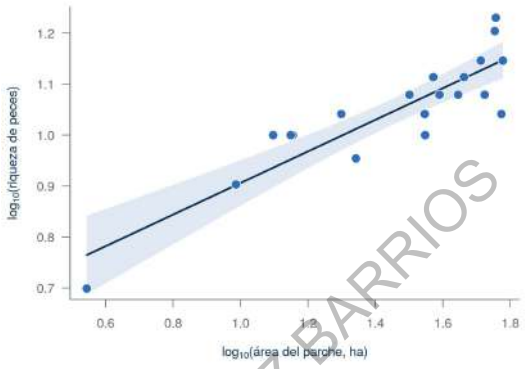
$$\log_{10}(\text{riqueza}) = 0.596 + 0.310 \times \log_{10}(\text{área})$$

```
# Modelo log-log
mod_sp <- lm(log10(riqueza) ~ log10(area_ha), data = manglar)
```

¿Cómo se lee la pendiente en escala log-log?

Cada 1 % de área ≈ 0.31 % más especies.
Duplicar el área multiplica la riqueza por ≈ 1.24 (**+24 %**).

b_1 es el exponente z de la ley $S = c \cdot A^z \approx 2^{(0,31)} = 1{,}24$.



Banda: IC 95 % de la recta ajustada.

Pendiente (b_1)	IC 95 %	r^2	Valor p
0.310	0.23 – 0.39	0.79	1.8×10^{-7}

7

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

¿ES REAL EL EFECTO?

Inferencia sobre los coeficientes

```
summary(mod_sp)   # coeficientes, t, p y r²
confint(mod_sp)   # IC 95 % de b0 y b1
```

Prueba t sobre la pendiente $Y = \beta_0 + \beta_1 X + \varepsilon$

H_0: $\beta_1 = 0$ (no hay relación).
Se calcula $t = b_1 / EE(b_1) = 0.3100 / 0.0379 =$ **8.18**, con gl = n − 2 = 18 → **$p = 1.8 \times 10^{-7}$**.

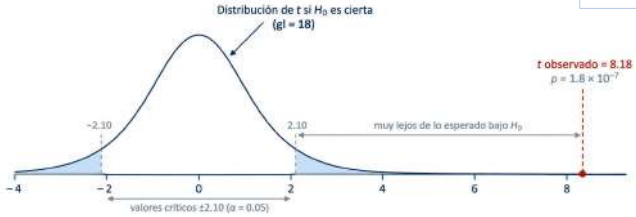
Intervalo de confianza de la pendiente

$b_1 \pm t_{0.025,18} \times EE =$ **[0.23, 0.39]**. Como no incluye 0, se rechaza H_0 con $\alpha = 0.05$. El **r^2** indica qué proporción de la variación en Y explica el modelo, no si el efecto es real.

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept)    0.59590    0.05651  10.545 3.92e-09 ***
log10(area_ha) 0.31002    0.03788   8.184 1.77e-07 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.05429 on 18 degrees of freedom
Multiple R-squared:  0.7882,    Adjusted R-squared:  0.7764
F-statistic: 66.98 on 1 and 18 DF,  p-value: 1.77e-07
```

```
                 2.5 %    97.5 %
(Intercept)    0.4771772 0.7146295
log10(area_ha) 0.2304358 0.3896078
```



$\log_{10}(\text{riqueza}) = 0.596 + 0.310 \times \log_{10}(\text{área})$

Cada 1 % de área ≈ 0.31 % más especies.

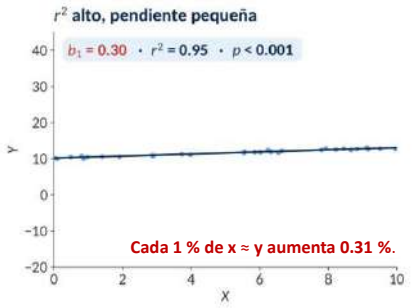
8

¿ES REAL EL EFECTO?

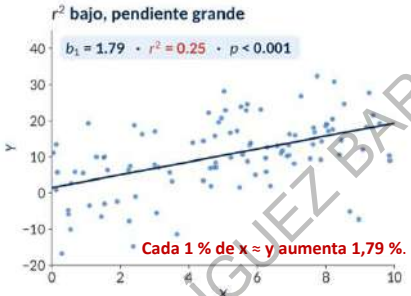
Inferencia sobre los coeficientes

Confusión común

Un r^2 alto no garantiza causalidad; un r^2 bajo no significa que la pendiente sea nula. Son preguntas distintas.



Los puntos se ajustan muy bien, pero Y apenas cambia con X.



Mucha dispersión, pero Y cambia mucho con X.

9

MATERIAL DE CLASE - JAVIER RODRIGUEZ BARRIOS

ANTES DE CONFIAR EN EL MODELO

Supuestos y diagnóstico

Linealidad

La relación es aproximadamente recta (o lo es tras una transformación, como log-log).

Se revisa con: Residuos vs. ajustados

Normalidad

Los residuos del modelo se aproximan a una distribución normal.

Se revisa con: Gráfico Q-Q · shapiro.test()

Homocedasticidad

La dispersión de los residuos es similar en todo el rango de X, sin forma de embudo.

Se revisa con: Escala-localización

Independencia

Cada observación aporta información nueva. Es el supuesto más crítico.

Se revisa con: Diseño de muestreo

En R, plot(modelo) genera los cuatro gráficos de diagnóstico de una vez; se practican en el taller de esta sesión.

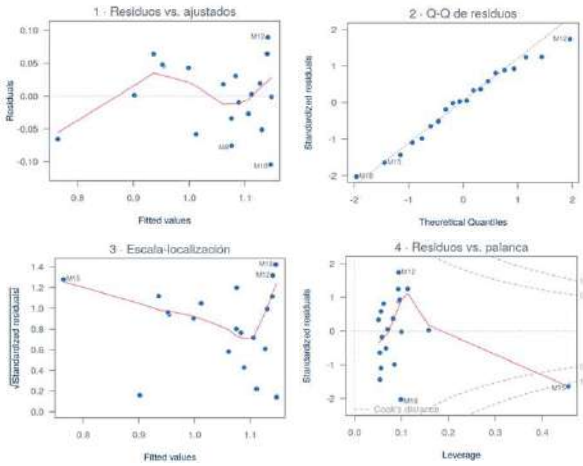
La independencia no se verifica con un gráfico: depende del diseño (pseudorreplicación, autocorrelación espacial o temporal entre estaciones).

10

VOLVIENDO AL EJEMPLO DEL MANGLAR

Los cuatro gráficos de diagnóstico

$$\log_{10}(\text{riqueza}) = 0.596 + 0.310 \times \log_{10}(\text{área})$$




```
par(mfrow = c(2, 2)); plot(mod_sp)
```

1. **Residuos vs. ajustados**
   Nube sin patrón alrededor de 0 → **linealidad** razonable.
2. **Q-Q de residuos**
   Puntos sobre la diagonal → **normalidad** razonable.
3. **Escala-localización**
   Sin embudo claro → **varianza constante**; la curva la arrastra un solo punto (M15).
4. **Residuos vs. palanca**
   El parche **M15** supera la **distancia de Cook = 1**: es una observación influyente.

```
shapiro.test(resid(mod_sp))
```

```
W = 0.97553, p-value = 0.8645
```

p > 0.05: no se rechaza la normalidad de los residuos.

11

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

UN PUNTO QUE PESA DEMASIADO

Una observación influyente: el parche M15

M15 (3.5 ha) es el **único parche pequeño** de la muestra: el siguiente mide 9.7 ha. En escala logarítmica queda aislado en el extremo y tiene mucha palanca sobre la pendiente (Cook = 1.12).

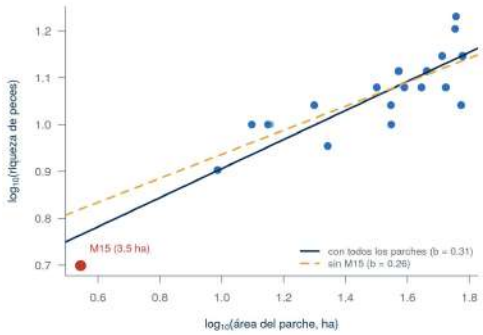
$$\log_{10}(\text{riqueza}) = 0.596 + 0.310 \times \log_{10}(\text{área})$$

Cada 1 % de área ≈ 0.31 % más especies.

```
cd <- cooks.distance(mod_sp)
mod_sp_sin <- update(mod_sp, subset = -which.max(cd))
```

```
           (Intercept) log10(area_ha)
con_todos    0.5959034      0.3100218
sin_M15      0.6799944      0.2564423
```

```
                  2.5 %    97.5 %
log10(area_ha) 0.1562127 0.3566719
```



Sensibilidad del resultado

Sin M15, la pendiente baja de 0.31 a **0.26**, pero su IC [0.16, 0.36] sigue excluyendo 0: **la conclusión se mantiene**.

No se elimina por conveniencia. Se puede reportar el modelo con y sin el punto.
Lección de diseño: si se analiza en escala log, conviene muestrear el gradiente de área de forma pareja en esa escala (~1, 3, 10, 30 ha).

12

CUANDO LA RECTA NO ALCANZA

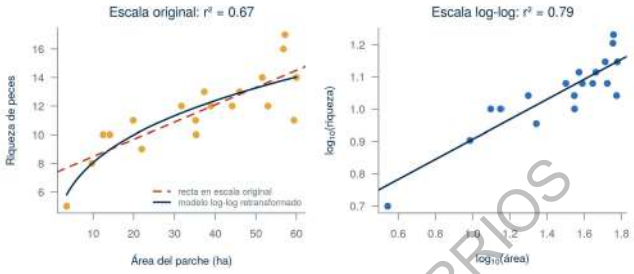
Cuando la relación no es lineal

El problema

Muchas relaciones ecológicas (especie-área, dosis-respuesta, crecimiento) no son rectas en su escala original: crecen rápido al inicio y luego se desaceleran.

La solución más simple: transformar

El logaritmo de una o ambas variables suele **linealizar** relaciones multiplicativas. Es lo que se aplicó en el ejemplo del manglar: $\log_{10}$(riqueza) vs. $\log_{10}$(área).



El r^2 sube de 0.67 a 0.79 solo por cambiar de escala: la recta en escala original no sigue la curva especie-área; en log-log los puntos se alinean.

$\log_{10}(\text{riqueza}) = 0.596 + 0.310 \times \log_{10}(\text{área})$

Cómo se verifica y qué se gana

Se comparan los gráficos de residuos antes y después de transformar.

Si la respuesta es un **conteo** (como la riqueza), el **GLM Poisson** es una alternativa a utilizar.

13

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

UN PREDICTOR NO SIEMPRE BASTA

Regresión múltiple

El modelo

$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \varepsilon$. Extiende la regresión simple para incluir varios predictores a la vez.

¿Por qué usarla?

Casi ningún fenómeno ecológico depende de una sola variable. Incluir los predictores relevantes reduce el riesgo de **atribuir a uno el efecto de otro**.

```
lm(crecimiento ~ temperatura + profundidad)
```

Pregunta para discusión

El **crecimiento coralino** aumenta con la **temperatura**… ¿hasta dónde? Por encima del umbral de blanqueamiento la relación se invierte.

¿Qué implica esto para **extrapolar** un modelo lineal fuera del rango de temperaturas muestreado?

Ejemplo aplicado — Caribe colombiano

El crecimiento de coral no solo depende de la temperatura: la profundidad también influye (menos luz, menos crecimiento). Un modelo múltiple estima ambos efectos a la vez.

14

EJEMPLO TRABAJADO

Crecimiento de coral: temperatura y profundidad

Pregunta: ¿cómo afectan la temperatura (°C) y la profundidad (m) al crecimiento de coral (mm/año), de forma simultánea? (n = 32 colonias).

$$\text{crecimiento} = -8.73 + 0.40 \times \text{temperatura} - 0.075 \times \text{profundidad} + \varepsilon$$

Predictor	b	IC 95 %	Valor p
Temperatura (°C)	+0.401	[0.30, 0.50]	< 0.001
Profundidad (m)	−0.075	[−0.10, −0.05]	< 0.001

R^2 ajustado = 0.70 (R^2 = 0.72): el modelo explica ≈ 70 % de la variación del crecimiento. En regresión múltiple se reporta el R^2 **ajustado**, que penaliza el número de predictores.

```
mod_coral <- lm(crecimiento ~ temperatura + profundidad, data = coral)
summary(mod_coral); confint(mod_coral)
```

```
Coefficients:
             Estimate Std. Error t value Pr(>|t|)
(Intercept) -8.73281    1.40107  -6.233 8.42e-07 ***
temperatura  0.40079    0.05084   7.883 1.08e-08 ***
profundidad -0.07507    0.01281  -5.862 2.33e-06 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

Residual standard error: 0.4478 on 29 degrees of freedom
Multiple R-squared:  0.7227,    Adjusted R-squared:  0.7036
F-statistic: 37.79 on 2 and 29 DF,  p-value: 8.381e-09
```

```
                 2.5 %      97.5 %
(Intercept) -11.5983095 -5.86730277
temperatura   0.2968150  0.50477291
profundidad  -0.1012643 -0.04887736
```

$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \varepsilon$

Cada °C de temp. ≈ 0.4 más crec. (mm/año).

Cada m de prof. ≈ 0,075 menos crec. (mm/año).

15

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

INTERPRETANDO EL MODELO MÚLTIPLE

Coeficientes parciales

¿Qué significa cada b ahora?

Cada coeficiente es el efecto de esa variable **manteniendo constantes las demás**; por eso se llaman coeficientes parciales.

Aplicado al ejemplo del coral

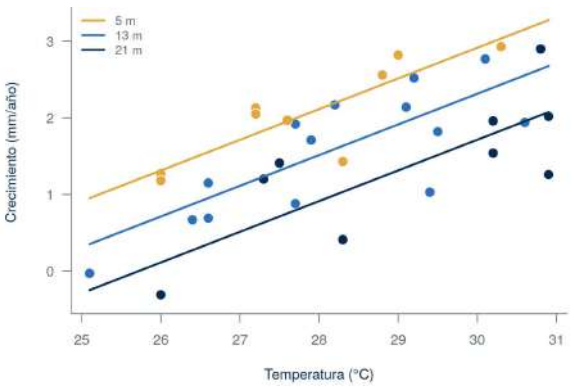
b = 0.40 para temperatura: por cada °C adicional, el crecimiento aumenta 0.40 mm/año, **comparando colonias a la misma profundidad** (líneas paralelas de la figura).

Crec. = − 8.73 + 0.40 temp. − 0.075 prof. + ε

Por qué importa la diferencia

Con solo la temperatura, la pendiente es **0.31** mm/año por °C: **subestima** el efecto.

Por azar, en esta muestra las colonias más cálidas quedaron algo más profundas (r = 0.30), y la profundidad reduce el crecimiento: su efecto negativo se mezcla con el de la temperatura.




```
mod_temp <- lm(crecimiento ~ temperatura, data = coral)
```

```
         temperatura
simple     0.3113164
parcial    0.4007940
```


16

UN RIESGO DE LA REGRESIÓN MÚLTIPLE

Multicolinealidad

El problema

Cuando dos predictores (x_i) están muy correlacionados, el modelo no puede separar el efecto de cada uno: los coeficientes se vuelven **inestables** y sus IC se ensanchan.

Cómo se detecta: el VIF

El Factor de Inflación de Varianza cuantifica cuánto se infla la varianza de un coeficiente por su correlación con los demás predictores. **VIF > 5–10** es señal de alerta.

```
vif_manual(mod_coral)   # función del taller ≈ car::vif()
cor(coral$temperatura, coral$profundidad)
```

```
temperatura profundidad
   1.099086    1.099086
[1] 0.3002552
```

Con dos predictores el VIF es **idéntico para ambos**:
$1 / (1 - r^2)$, con r = 0.30.
VIF ≈ 1.10: no hay problema de colinealidad.

Pregunta para discusión: si solo se muestrearan sitios donde la temperatura cae fuertemente con la profundidad (termoclina marcada), ¿qué pasaría con el VIF y con la interpretación de cada coeficiente? ¿Cómo lo evitaría el diseño de muestreo?

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

¿CON QUÉ MODELO SE QUEDA EL ANÁLISIS?

Selección de modelos

El criterio: AIC

El Criterio de Información de Akaike equilibra ajuste y complejidad: penaliza los predictores que no aportan. **Menor AIC = mejor equilibrio**.
ΔAIC < 2 indica modelos prácticamente equivalentes.

Modelos anidados

anova(modelo_simple, modelo_completo) evalúa con una prueba F si añadir un predictor **reduce significativamente** la variación residual.

Resultado en el ejemplo del coral

Agregar la turbidez sube el r^2 (0.723 → 0.728), pero no mejora el AIC (ΔAIC = 1.4, soporte similar) ni la prueba F (p = 0.48): por **parsimonia** se conserva temperatura + profundidad.

Modelo parsimonioso: $Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \varepsilon$

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \beta_3 X_3 + \beta_4 X_4 + \varepsilon$$

```
# tabla_aic del taller (r², AIC y ΔAIC)
```

```
              modelo    r2   AIC  dAIC
       temp + prof 0.723 44.24  0.00
 temp + prof + turb 0.728 45.65  1.41
               temp 0.394 67.25 23.01
               prof 0.128 78.89 34.65
```

```
anova(mod_coral, mod_full)
```

```
Analysis of Variance Table

Model 1: crecimiento ~ temperatura + profundidad
Model 2: crecimiento ~ temperatura + profundidad + turbidez
  Res.Df    RSS Df Sum of Sq      F Pr(>F)
1     29 5.8152
2     28 5.7088  1   0.10634 0.5216 0.4762
```

Regla práctica: step() automatiza la búsqueda, pero solo entre candidatos con sentido biológico. Sus valores de AIC difieren de AIC() en una constante; el orden de los modelos es el mismo.

PLANEAR ANTES DE SALIR A CAMPO

Tamaño de muestras- *lm* simple

¿Cuántas estaciones de fondo blando se necesitan (n) para detectar que la diversidad funcional (FD) disminuye con la materia orgánica (MO)?

Un piloto o la literatura sugiere un **R^2 esperado ≈ 0.30**.
Se traduce al tamaño del efecto de Cohen:

$$f^2 = R^2 / (1 - R^2) = 0.30 / 0.70 = 0.43$$

Ejemplo. Bentos de fondos blandos

Un predictor x_i (u = 1), α = 0.05, potencia = 80 %:

n ≈ 21 estaciones requeridas

Referencia de Cohen	pequeño	mediano	grande
f^2	0.02	0.15	0.35
R^2 equivalente	0.02	0.13	0.26
n necesario (u = 1)	395	55	25

$$FD = 0.596 + 0.310 \times MO$$

n = tamaño de la muestra o n.º de unidades experimentales.
u = predictores (x_i) que se prueban (solo 1).
v = grados de libertad del error. **v** = n − u − 1. Entonces **n** = ⌈v⌉ + u + 1
f_2 = tamaño del efecto. $f^2 = R^2 / (1 - R^2)$. Con $R^2 = 0.30$, los predictores explican 0.30 frente a 0.70 de residuo, y $f^2 = 0.43$.
R^2 = variación explicada del predictor (x_i).

```
# Tamaño de muestra para una pendiente
library(pwr)
pwr.f2.test(u = 1, f2 = 0.43, sig.level = 0.05,
            power = 0.80)
```

```
     Multiple regression power calculation

              u = 1
              v = 18.42546
             f2 = 0.4285714
          power = 0.8
```

Ojo: pwr.f2.test() devuelve v, no n.
El tamaño de muestra es **n = ⌈v⌉ + u + 1 = 19 + 1 + 1 = 21**.

Cuanto más pequeño el efecto que se quiere detectar, más unidades experimentales o muestras se necesitan.

MATERIAL DE CLASE - JAVIER RODRIGUEZ BARRIOS

PLANEAR ANTES DE SALIR A CAMPO

Regresión múltiple- *lm* múltiple

Mismo bentos, ahora con **profundidad + MO**. La pregunta define **u** y f^2; de ahí sale el n. Un piloto sugiere $R^2 = 0.20$ con la profundidad sola y 0.30 al agregar la MO.

n = tamaño de la muestra o n.º de unidades experimentales.
u = predictores (x_i) que se prueban (2 variables).
v = grados de libertad del error. **v** = n − u − 1. Entonces **n** = ⌈v⌉ + u + 1
f_2 = tamaño del efecto. $f^2 = (R^2_{AB} - R^2_A) / (1 - R^2_{AB})$. Es lo que gana el modelo al agregar predictores (x_i), en relación a lo que aún no explica.
R^2 = variación explicada del predictor (x_i).

1 ¿El modelo completo explica algo?

$$f^2 = R^2 / (1 - R^2)$$

u = número de predictores = 2
$R^2 = 0.30 \rightarrow f^2 = 0.43$

n ≈ 26 estaciones

2 ¿La MO aporta por encima de la profundidad?

$$f^2 = (R^2_{AB} - R^2_A) / (1 - R^2_{AB})$$

u = 1 (solo el predictor)
R^2: 0.20 → 0.30 → $f^2 = 0.14$

n ≈ 57 estaciones

```
f2_parcial <- (0.30 - 0.20) / (1 - 0.30)   # 0.143
pwr.f2.test(u = 1, f2 = f2_parcial, power = 0.80)
```

```
     v = 54.92805     # n = 55 + 1 + 1 = 57
   (u = 2, f2 = 0.43: v = 22.73 → n = 26)
```

No se planea con el r^2 del propio estudio. Con el del manglar (0.79 → $f^2 = 3.72$) saldría n = 5: una cifra absurda, porque la «potencia observada» solo repite el valor p. Se planea con un piloto, la literatura o el efecto mínimo con relevancia biológica.

PLANEAR ANTES DE SALIR A CAMPO

RA1

¿Y si el tamaño de muestra no alcanza?

La potencia depende del tamaño del efecto y también de cómo se distribuyen las estaciones a lo largo del gradiente ambiental.

CASO 1 · TURBIDEZ

32 colonias · p = 0.48

Potencia ≈ 11 %

El aporte de la turbidez es pequeño ($f^2 \approx 0.02$): para 80 % de potencia harían falta ≈ 424 colonias.

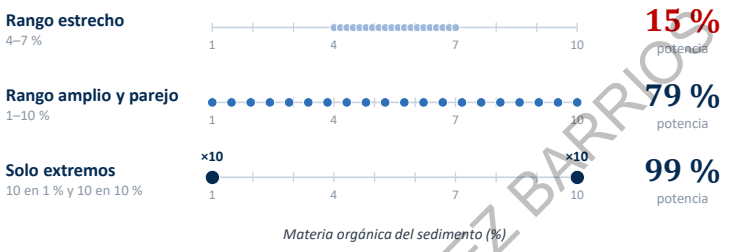
No detectar el efecto no demuestra que no exista.

¿QUÉ SE PUEDE HACER?

1. **Definir el efecto mínimo detectable**
   ¿Qué efecto puede detectar el n disponible?
2. **Mejorar el diseño**
   Cubrir un rango relevante y medir covariables.
3. **Interpretar como estimación**
   Informar la pendiente y su IC 95 %, no solo p.

CASO 2 · SIMULACIÓN: MISMAS 20 ESTACIONES

Cada punto es una estación. Se mantienen la misma pendiente y el mismo error residual; solo cambia cómo se distribuyen las 20 estaciones en el gradiente de MO. Se simularon 5000 estudios por diseño.



Idea clave: con el mismo n, repartir las estaciones a lo largo de todo el gradiente aumenta la potencia. Solo extremos la maximiza, pero **impide detectar curvaturas o umbrales**: el diseño debe responder la pregunta ecológica, no solo dar significancia.

21

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

ANTES DE REPORTAR EL MODELO

Lista de verificación de un buen modelo de regresión

1. ¿Se verificó que la relación es lineal (o se transformó para que lo sea)?
2. ¿Se revisaron los residuos: normalidad, homocedasticidad y puntos influyentes?
3. ¿El diseño garantiza la independencia de las observaciones?
4. ¿El IC 95 % de cada pendiente de interés excluye el 0?
5. ¿Se interpretó r^2 (o R^2 ajustado) como variación explicada y no como causalidad?
6. ¿Se evaluó el VIF y se compararon modelos candidatos con AIC, sin extrapolar?

22

DE LA TABLA A SUS PROYECTOS

Misma lógica, distinto modelo: depende de la pregunta y del diseño

Pregunta de investigación *mismos proyectos de la Semana 1*	Si se cumplen supuestos Regresión lineal (lm)	Si fallan Transformar o cambiar de modelo	Qué revisar antes El error típico de ese diseño
LANGOSTA ESPINOSA **¿Disminuye el crecimiento de juveniles al aumentar la densidad de cultivo?**	Densidad continua `lm(crec ~ densidad)`	Curva de saturación `log(crec) o poly(densidad, 2)`	n = tanques, no langostas; no extrapolar fuera de las densidades ensayadas.
CHLOROPHYTA · CARBONO **¿Aumenta el carbono almacenado con la biomasa algal?**	Relación alométrica `lm(log(C) ~ log(biomasa))`	Varianza creciente `log-log o GLM Gamma`	Es mensurativo: concluye asociación, no causa.
BENTOS DE FONDOS BLANDOS **¿Disminuye la diversidad funcional con el % de materia orgánica del sedimento?**	Gradiente continuo `lm(FD ~ MO)`	Relación curva `lm(FD ~ log(MO))`	Estaciones cercanas no son independientes: revisar autocorrelación espacial.
MACROINVERTEBRADOS · RÍO CAÑAS **¿Se relaciona el índice biótico con el oxígeno y la conductividad?**	Dos predictores `lm(indice ~ OD + cond)`	Residuos no normales `transformar el índice`	OD y conductividad covarían (VIF); 6 estaciones × 2 épocas = pocos gl.

Prueba rápida — Tres preguntas, en orden

1 · ¿Qué es respuesta y qué es predictor? Define el modelo y el n real

2 · ¿La relación es lineal? O linealizable con log o raíz

3 · ¿Qué tipo de respuesta es? Continua → lm · conteo/binaria → GLM

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

EJERCICIO EN PAREJAS · 10 MINUTOS

El modelo del proyecto de grado

En parejas, se responde sobre el proyecto de grado de cada integrante:

- ¿Qué variable continua se busca explicar o proyectar?
- ¿Con uno o varios predictores? ¿Cuáles, y con qué justificación biológica?
- ¿Se esperaría necesitar una transformación (log, raíz)… o un GLM, porque la respuesta es un conteo o una presencia/ausencia?

RECURSOS Y PRÓXIMOS PASOS

¿Qué sigue después de esta sesión?

Para reforzar

- Practicar lm(), plot(), confint(), cooks.distance(), vif_manual() y AIC() en el taller de esta sesión.
- Resolver el cuestionario de refuerzo de regresión lineal.
- Cerrar la Evidencia 1 con el propio conjunto de datos (inferencia + regresión).

Sábado 2:00–6:00 pm

Modelos Lineales Generalizados: binomial y Poisson

- Cuándo la regresión lineal ya no aplica (datos binarios o de conteo).
- GLM binomial: ocupación, presencia/ausencia.
- GLM Poisson: abundancias, conteos.
- Abre la Evidencia 2 (GLM).

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS