BIOESTADÍSTICA · SEMANA 2 · 2026-II

Modelos Lineales Generalizados (GLM)

Binomial y Poisson: cuando la variable respuesta no es continua — RA1 · RA2

Javier Rodríguez Barrios

Maestría en Ecología y Biodiversidad · Universidad del Magdalena

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

1

AGENDA DE LA SESIÓN

De la regresión a modelos acordes con los datos

Por qué la regresión lineal no basta
Datos binarios y de conteo requieren otra lógica. RA2

Los tres componentes de un GLM
Aleatorio, sistemático y función de enlace. RA2

GLM binomial
Presencia/ausencia, enlace logit y odds ratio. RA2

GLM Poisson
Conteos, enlace log, razón de tasas y offset. RA2

Sobredispersión
Cuándo Poisson no basta y cómo se corrige. RA2

Síntesis y ejercicio
Árbol de decisión y proyecto de grado. RA1 · RA2

2

ANTES DE EMPEZAR

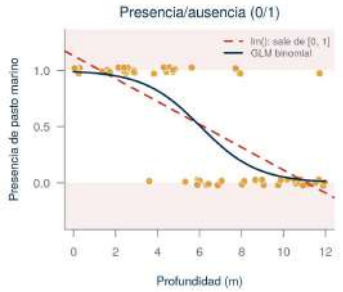
Cuando la variable respuesta no es continua ni normal

En la sesión anterior se ajustó lm() a variables continuas: *riqueza de peces* y *crecimiento de coral*.

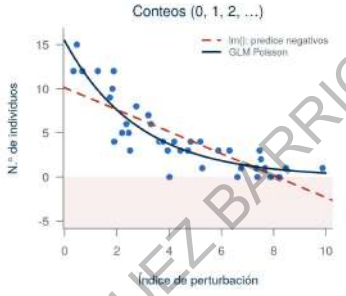
Si la respuesta es **presencia/ausencia (0/1)**, una recta puede proyectar probabilidades negativas o mayores que 1.

Si es un **conteo (0, 1, 2, …)**, una recta puede proyectar abundancias negativas.

Además, en estos datos la **varianza depende de la media**: los residuos casi nunca son normales ni homocedásticos.



Datos ilustrativos · zonas rojas: proyecciones biológicamente imposibles.



"Los GLM extienden el modelo lineal para que la escala de proyección respete la naturaleza biológica del dato."

MATERIAL DE CLASE - JAVIER RODRIGUEZ BARRIOS

MÁS ALLÁ DEL MODELO LINEAL CLÁSICO

Los tres componentes de un GLM

1

Componente aleatorio

Distribución de Y dentro de la familia exponencial (gaussiana, binomial, Poisson…).

La varianza queda **ligada a la media**:

binomial Var = np(1 − p);

Poisson Var = μ.

2

Componente sistemático

El predictor lineal $\eta = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots$, estructuralmente igual al de lm():

Admite factores, covariables e interacciones.

3

Función de enlace g(μ)

Conecta la media esperada $\mu = E(Y)$ con el predictor lineal: $\eta = g(\mu)$.

Lleva el rango restringido de Y (0–1, ≥ 0) a (−∞, +∞).

Diferencia clave con transformar Y: log(Y) altera cada observación y falla con los ceros (log 0 = −∞), lo que obliga a recursos como log(Y + 1).
En un GLM el enlace actúa sobre μ, no sobre los datos: la varianza se modela en su escala real y no hay proyecciones imposibles.

ELEGIR LA FAMILIA CORRECTA

¿Qué familia según la variable respuesta?

Tipo de variable respuesta	Familia	Enlace	Ejemplo ecológico
Continua, aprox. normal	Gaussiana	Identidad	Longitud corporal de un pez
Binaria (0/1) o proporción	Binomial	Logit	Presencia/ausencia de una especie
Conteo (0, 1, 2, …)	Poisson	Log	N.° de individuos por cuadrante
Conteo sobredisperso	Binomial negativa	Log	Peces por transecto (cardúmenes)

```
# Presencia/ausencia (0/1)
glm(y ~ x, family = binomial)
# Proporciones: éxitos y fracasos por unidad
glm(cbind(exitos, fracasos) ~ x, family = binomial)
# Conteos
glm(y ~ x, family = poisson)
```

Proporciones: el n importa

Se modelan con los conteos de éxitos y fracasos (o con weights), no con el porcentaje suelto: 3 de 4 y 30 de 40 no aportan la misma información.

5

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

DATOS BINARIOS Y DE PROPORCIONES

GLM binomial: función logit

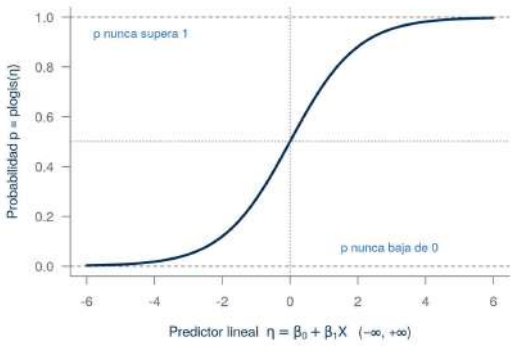
$$\text{logit}(p) = \ln[\, p / (1 - p)\,] = \beta_0 + \beta_1 X$$

¿Qué resuelve el enlace logit?

Lleva una probabilidad (0 a 1) a toda la recta real. Así, para cualquier valor de X, la probabilidad predicha con **plogis()** queda siempre entre 0 y 1.

Interpretación: odds ratio (OR)

OR = exp(β_1): cambio multiplicativo en los odds p/(1 − p) por cada unidad de X. OR > 1 aumenta la probabilidad del evento; OR < 1 la reduce.



Cuidado: OR ≠ cambio en la probabilidad. Un OR de 1.65 no significa +65 % de probabilidad: el efecto sobre p depende del tramo de la curva (es máximo cerca de p = 0.5).

6

EJEMPLO TRABAJADO

Enfermedad de banda negra en coral y temperatura

Pregunta: ¿Aumenta con la temperatura del agua la probabilidad de que una colonia presente signos de banda negra? (n = 80 colonias).

$$\text{logit}(p) = -14.77 + 0.50 \times \text{temperatura}$$

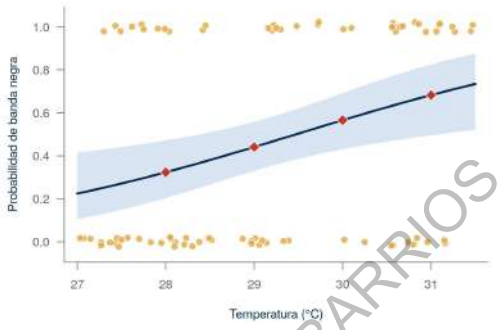
```
mod_enf <- glm(enfermo ~ temperatura, family = binomial, data = coral_enf)
exp(cbind(OR = coef(mod_enf), confint(mod_enf)))
```

```
                OR    2.5 %   97.5 %
temperatura 1.650694 1.178433 2.376991
```

Interpretación

Por cada +1 °C, los odds de enfermedad se multiplican por **1.65** (IC 95 %: 1.18–2.38), es decir, **+65 % en los odds**.

Como el IC del OR excluye 1, la asociación es estadísticamente significativa.



Banda: IC 95 % · rombos: probabilidades proyectadas.

P(28 °C)	P(29 °C)	P(30 °C)	P(31 °C)
32 %	44 %	57 %	68 %

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

¿ES REAL EL EFECTO?

Del logit a la decisión: lectura de la salida

Prueba de Wald (z)

$z = b_1 / EE = 0.501 / 0.178 = \mathbf{2.82} \rightarrow p = 0.005$.

Un GLM usa z y no t, porque la varianza la fija la familia.

Prueba de razón de verosimilitud

Compara la devianza con y sin temperatura: $\chi^2 = \mathbf{8.69}$, gl = 1, **p = 0.003**. Es la prueba preferida con muestras pequeñas.

Significativo no es lo mismo que explicativo

La temperatura reduce la devianza solo un **7.9 %** (110.45 → 101.76): hay efecto, pero otros factores (hospedero, sedimentación, patógenos) explican la mayor parte de la variación.

```
summary(mod_enf)
anova(mod_enf, test = "Chisq")
```

```
Coefficients:
            Estimate Std. Error z value Pr(>|z|)
(Intercept) -14.7714     5.1927  -2.845  0.00445 **
temperatura   0.5012     0.1777   2.821  0.00479 **

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 110.45  on 79  degrees of freedom
Residual deviance: 101.76  on 78  degrees of freedom
AIC: 105.76
```

```
Analysis of Deviance Table
            Df Deviance Resid. Df Resid. Dev Pr(>Chi)
NULL                           79     110.45
temperatura  1   8.6931        78     101.76 0.003194 **
```

En el taller se centra la temperatura (temperatura − 29) para que el intercepto sea el logit a 29 °C y no a 0 °C, un valor sin sentido biológico.

DATOS DE CONTEO

GLM Poisson: función log

$$\log(\mu) = \beta_0 + \beta_1 X \;\Rightarrow\; \mu = \exp(\beta_0 + \beta_1 X)$$

¿Qué resuelve el enlace log?

Garantiza que la abundancia esperada μ sea siempre positiva: exp() nunca devuelve un número negativo.

Interpretación: razón de tasas

exp(β₁): factor por el que se multiplica la abundancia esperada por cada unidad de X. Supuesto de partida: **equidispersión** (Var = μ).

Esfuerzo desigual: offset

Si los parches, transectos o lances difieren en área o duración, se modela la **tasa** con un offset. Sin él, una unidad grande parece más abundante solo por su tamaño.

```
y ~ x + offset(log(area))
```

Ejemplos aplicados — Caribe colombiano

Juveniles de langosta por parche de pastos marinos, peces por transecto de arrecife, macroinvertebrados por red en el río Cañas, nidos de tortuga por km de playa.

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BATRIOS

EJEMPLO TRABAJADO

Juveniles de langosta espinosa y densidad de pastos

Pregunta: ¿Aumenta el número de juveniles de *Panulirus argus* por parche de pastos marinos (Gayraca) con la densidad del pasto? (n = 32).

$$\log(\mu) = 0.83 + 0.150 \times \text{densidad_pasto}$$

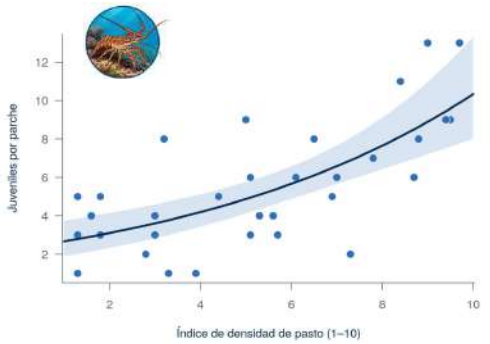
```
mod_lang <- glm(juveniles ~ densidad_pasto,
                family = poisson, data = langosta)
exp(confint(mod_lang)); phi(mod_lang)
```

```
                   2.5 %   97.5 %
(Intercept)    1.533645 3.350367
densidad_pasto 1.098824 1.230965
[1] 1.005818
```

Interpretación

Por cada unidad del índice, la abundancia esperada se multiplica por **1.16** (+16 %).

ϕ = 1.01: hay equidispersión y el Poisson, sin corrección, es adecuado.



Curva: exp(predicción) · banda: IC 95 %.

Razón de tasas	IC 95 %	Valor p	ϕ
1.16	1.10 – 1.23	2×10^{-7}	1.01

CUANDO POISSON NO BASTA

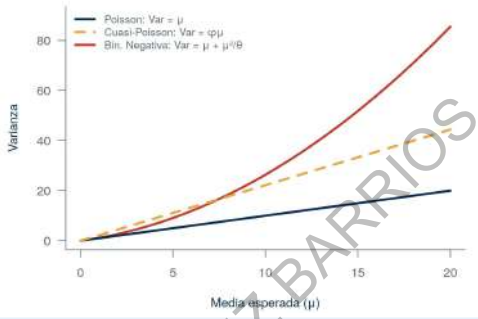
Sobredispersión: el supuesto que casi siempre se rompe

Pregunta: ¿Aumenta el número de juveniles de *Panulirus argus* por parche de pastos marinos (Gayraca) con la densidad del pasto? (n = 32).



$$\varphi = \Sigma\ (\text{residuos de Pearson})^2\ /\ \text{g.l. residuales}$$

ϕ ≈ 1: equidispersión · **ϕ > 1.2–2: sobredispersión**



Causas ecológicas típicas

Agregación biológica: cardúmenes, colonias, parches.
Covariables clave no medidas (sustrato, corrientes).
Exceso de ceros: unidades fuera del hábitat óptimo.

Cuasi-Poisson — `family = quasipoisson`

Var = ϕμ. Mismos β del Poisson; el EE se multiplica por √ϕ. No es una distribución completa: **no permite AIC**.

Binomial negativa — `MASS::glm.nb(y ~ x)`

Var = μ + μ²/θ. Añade el parámetro θ (menor θ, más agregación). Modelo completo: **sí permite AIC**.

MATERIAL DE CLASE - JAVIER RODRIGUEZ BARRIOS

EJEMPLO TRABAJADO

RA2

Pez loro: zonas, épocas y sobredispersión

Pregunta: ¿difiere la abundancia de *Scarus iseri* entre zonas de uso y entre épocas? (3 zonas × 2 épocas × 8 transectos; n = 48)

```
mod_p  <- glm(abundancia ~ zona * epoca, family = poisson)
mod_nb <- MASS::glm.nb(abundancia ~ zona * epoca)
phi(mod_p); phi(mod_nb); AIC(mod_p, mod_nb)
```

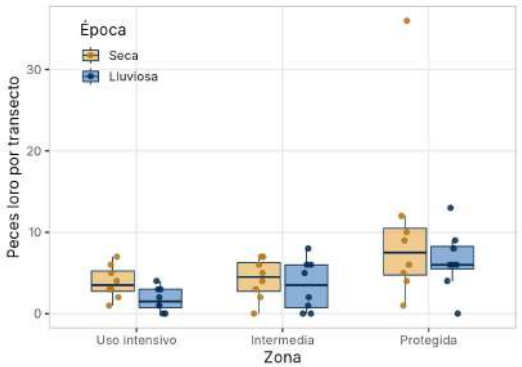
modelo	phi	AIC
Poisson	3.38	295.1
Binomial negativa	1.03	252.8

Interpretación

Con **ϕ = 3.38**, el Poisson subestima los EE: en la zona protegida, el EE pasa de 0.17 (Poisson) a 0.28 (binomial negativa).

La binomial negativa deja ϕ ≈ 1 y baja el AIC (**295.1 → 252.8**). El cuasi-Poisson corrige el EE de forma parecida (0.31), pero no permite AIC.

Interacción zona × época: p = 0.59 → modelo aditivo.



La zona protegida en época seca: media 10.4, varianza 119.7.

ϕ (Poisson)	RT protegida (NB)	IC 95 % (NB)	θ
3.38	3.05	1.78 – 5.28	2.73

SÍNTESIS

El árbol de decisión: ¿qué modelo se ajusta?

¿Cómo es la variable respuesta?

Continua y ≈ normal

`lm()` · `glm(family = gaussian)`

Enlace: identidad
Ej.: talla de peces

Binaria o proporción

`glm(family = binomial)`

Enlace: logit
Ej.: presencia/ausencia

Conteo (0, 1, 2, …)

`glm(family = poisson)`

Enlace: log
Ej.: individuos por cuadrante

La unidad experimental define el n. Colonias de un mismo arrecife o juveniles de un mismo tanque no son réplicas independientes.

¿Proporciones con ϕ > 1?
`family = quasibinomial`

¿ϕ > 1.2 en el Poisson?
`quasipoisson` · `MASS::glm.nb()`

¿Muchos taxones?
`mvabund::manyglm(family = "negative.binomial")`
«Semana 4 · junto a PERMANOVA»

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

PLANEAR ANTES DE SALIR A CAMPO

RA1 · RA2

¿Cuántas unidades necesita un GLM?

`pwr` no cubre los GLM: la potencia se estima por simulación. Se fija el efecto en escala biológica, se simulan 1 000 estudios y se cuenta en cuántos la prueba de razón de verosimilitud da p < 0.05.

Binomial · banda negra

Fijos: OR = 1.5 por °C (piloto) · prevalencia 45 % a 29 °C

52 %	81 %	94 %
60 colonias	120 colonias	180 colonias

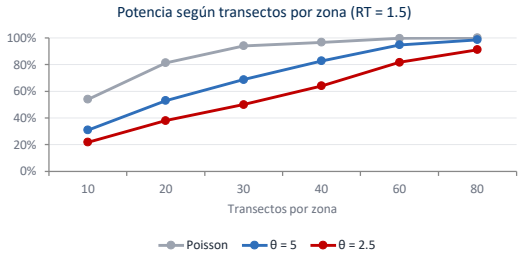
Con prevalencia de 10 %: ≈ 280 colonias para el mismo OR.

Conteos · pez loro, 2 zonas

Fijos: media 4 peces/transecto · RT = 1.5 · θ del piloto

82 %	35 %	83 %
Poisson · 20 por zona	θ = 2.5 · 20 por zona	θ = 2.5 · 60 por zona

La agregación triplica el esfuerzo: de 20 a ≈ 60 transectos por zona.



No se planea con el efecto observado

El OR de 1.65 salió de estos datos: usarlo es circular. Se usa un piloto, la literatura o el efecto mínimo relevante.

10 eventos por predictor ≠ potencia

Con prevalencia 10 % y 120 colonias hay ≈ 14 enfermas (cumple la regla), pero la potencia es ≈ 45 %.

ANTES DE REPORTAR EL GLM

Lista de verificación de un buen GLM

1. ¿Se eligió la familia según el tipo real de la variable respuesta?
2. ¿Se reportaron los efectos en escala interpretable (OR o razón de tasas) con su IC 95 %?
3. ¿Se evaluó el efecto con la prueba de razón de verosimilitud, además de Wald?
4. ¿Se calculó ϕ en los modelos Poisson y se corrigió si $\phi > 1.2$?
5. ¿Se incluyó un offset cuando el esfuerzo de muestreo difiere entre unidades?
6. ¿Se compararon modelos con AIC y se evitó extrapolar fuera del rango observado?

15

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

DE LA TABLA A SUS PROYECTOS

Misma lógica, distinta familia: depende del tipo de dato

Pregunta de investigación *mismos proyectos de las sesiones anteriores*	Respuesta y familia Tipo de dato → GLM	Si hay problemas Sobredispersión o esfuerzo	Qué revisar antes El error típico de ese diseño
LANGOSTA ESPINOSA **¿Depende la supervivencia de los juveniles del tipo de refugio?**	Vivos/muertos por tanque `cbind(vivos, muertos) ~ refugio`	$\phi > 1$ entre tanques `family = quasibinomial`	n = tanques: los juveniles de un mismo tanque no son independientes.
CHLOROPHYTA · CARBONO **¿Cambia la presencia de Chlorophyta con la profundidad?**	Presencia/ausencia `pres ~ prof, binomial`	Pocas presencias `reducir predictores`	Regla práctica: al menos 10 presencias por predictor.
BENTOS DE FONDOS BLANDOS **¿Disminuye la abundancia de poliquetos con la perturbación?**	Conteo por núcleo `abund ~ perturb, poisson`	Agregación, $\phi > 1.2$ `MASS::glm.nb()`	Exceso de ceros en las estaciones más perturbadas.
MACROINVERTEBRADOS · RÍO CAÑAS **¿Cambia la abundancia de EPT con el oxígeno disuelto?**	Conteo por muestra `EPT ~ OD, poisson`	Esfuerzo desigual `+ offset(log(area))`	Mismas estaciones en sequía y lluvias: medidas repetidas.

Prueba rápida — Tres preguntas, en orden

1 · ¿Qué tipo de dato es la respuesta? 0/1, proporción, conteo o continua

2 · ¿El esfuerzo es igual entre unidades? Si no lo es: offset

3 · ¿$\phi \approx 1$? Si no: cuasi o binomial negativa

16

EJERCICIO EN PAREJAS · 10 MINUTOS

El GLM del proyecto de grado

En parejas, se responde sobre el proyecto de grado de cada integrante:

- ¿La variable de interés es presencia/ausencia, una proporción o un conteo?
- Según eso, ¿qué familia y qué función de enlace corresponden?
- ¿Qué predictores ambientales o biológicos se incluirían, y con qué justificación?
- Si es un conteo, ¿se esperaría sobredispersión (agregación, parches, ceros) o un esfuerzo desigual que requiera offset?

17

MATERIAL DE CLASE - JAVIER RODRÍGUEZ BARRIOS

RECURSOS Y PRÓXIMOS PASOS

¿Qué sigue después de esta sesión?

Para reforzar

- Practicar glm(), anova(..., test = "Chisq"), plogis() y MASS::glm.nb() en el taller de esta sesión.
- Resolver el cuestionario de refuerzo de GLM.
- Cerrar la Evidencia 2 con datos binomiales o de conteo del propio proyecto.

Semana 3 — 23–24 de octubre

Multivariados I: bases de datos y exploración gráfica

- Manipulación de bases de datos multivariadas en Excel y R (tidyverse).
- Exploración y visualización gráfica en Quarto.
- Cierra con dos cuestionarios Quarto (Evidencia 3).

Con esta sesión se cierran las Evidencias 1 y 2 (inferencia, regresión y GLM). Para el taller, traer datos binomiales o de conteo del propio proyecto de tesis.

18